

1 基础概率

1.1 概率公理

1. 非负性 $P \geq 0$
2. 规范性对于必然事件 $P(\Omega) = 1$
3. 可列可加性对于两两互不相容的事件 $\{A_i\}, A_i A_j = \emptyset$.

$$P\left(\bigcup_{i=1}^{+\infty} A_i\right) = \sum_{i=1}^{+\infty} P(A_i) \quad (1)$$

1.2 公式

$$\begin{aligned} P\left(\bigcup A_i\right) &= \sum P(A_i) - \sum P(A_i A_j) + \sum P(A_i A_j A_k) + \dots + (-1)^{n-1} P(A_1 A_2 \dots A_n) \\ \left|\bigcup A_i\right| &= \sum |A_i| - \sum |A_i A_j| + \sum |A_i A_j A_k| + \dots + (-1)^{n-1} |A_1 A_2 \dots A_n| \\ |A - B| &= |A| - |AB| \end{aligned}$$

1.3 条件概率

$$P(A|B) = \frac{P(AB)}{P(B)} \quad (2)$$

假设 Ω 不变, 则条件 B 说明 B 成为全空间。概率即为 A 的测度比上 B 的测度。

1.4 Bayes 公式

设 $\{B_i\}$ 为 Ω 的一个划分

$$P(A|\Omega) = \sum P(B_i)P(A|B_i) \quad (3)$$

于是

$$P(B_i|A) = \frac{P(AB_i)}{P(A)} = \frac{P(B_i)P(A|B_i)}{\sum P(B_i)P(A|B_i)} \quad (4)$$

1.5 独立性

设 n 个事件 A_1, A_2, \dots, A_n , 相互独立要求

$$\begin{aligned} P(A_i A_j) &= P(A_i)P(A_j) \\ P(A_i A_j A_k) &= P(A_i)P(A_j)P(A_k) \\ &\dots\dots\dots \\ P(A_i A_j \dots A_n) &= \prod p(A_i) \end{aligned} \quad (5)$$

互斥一定不独立; 看成全空间下均匀散点比较好: 不均匀则有的地方”更浓”

2 随机变量

2.1 随机变量 is 函数

随机变量是 Ω 上的实单值函数 $X(\omega)$

2.2 分布函数

$$F(x) = P(X \leq x), \quad -\infty < x < +\infty \quad (6)$$

性质:

$$P(a < x \leq b) = F(b) - F(a)$$

$$P(X = x_0) = F(x_0) - F(x_0 - 0) \quad (7)$$

左极限存在, 右连续 $\lim_{t \rightarrow x^+} F(t) = F(x)$

2.3 离散型随机变量

离散型随机变量的可能取值是有限个, 设可能取值 $X = x_k$ ($k = 1, 2, \dots$), 不妨设 $x_1 < x_2 < \dots$, 称 $P(X = x_k) = p_k$, $k = 1, 2, \dots$ 为 X 的分布律, 且有:

$$\begin{aligned} p_k &\geq 0 \quad k = 1, 2, \dots \\ \sum_{k=1}^{+\infty} p_k &= 1 \end{aligned} \quad (8)$$

2.3.1 离散型随机变量分布律

二项分布 $X \sim B(n, p)$ 进行 n 次成功 k 次 $P(X = k) = C_n^k p^k (1-p)^{n-k}$

帕斯卡分布 成功 r 次恰需要 k 次, k 成功且前 $k-1$ 成功 $r-1$

$$P(X = k) = p C_{k-1}^{r-1} p^{r-1} (1-p)^{k-r} = C_{k-1}^{r-1} p^r (1-p)^{k-r} \quad (9)$$

Poisson 分布

定理: 若 $\lim_{n \rightarrow +\infty} np_n = \lambda > 0$,

$$\lim_{n \rightarrow +\infty} C_n^k p_n^k (1-p_n)^{n-k} = e^{-\lambda} \frac{\lambda^k}{k!} \quad (10)$$

Poisson 分布 $X \sim P(\lambda)$: 均匀概率密度, λ , 发生次数。

$$P(X = k) = e^{-\lambda} \frac{\lambda^k}{k!} \quad (11)$$

2.4 连续型随机变量

设 X 是一随机变量, $F(x)$ 是他的分布函数, 若存在一个非负可积函数 $f(X)$, 使得

$$F(x) = \int_{-\infty}^x f(t) dt, \quad -\infty < x < +\infty \quad (12)$$

则 X 是连续型随机变量, $f(x)$ 是概率密度函数, 且积上去不一定可导 (似乎一般可导):

$$\begin{aligned} f(x) &\geq 0 \\ \int_{-\infty}^{+\infty} f(x)dx &= F(+\infty) = 1 \\ f(x) &= F'(x) \quad \text{where } f(x) \text{ is continuous} \end{aligned} \quad (13)$$

2.4.1 连续性随机变量分布律

指数分布 $X \sim E(\lambda)$: 无记忆性 or 均匀概率密度, 相邻两次发生的间隔。

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0 \\ 0, & x \leq 0 \end{cases} \quad (\lambda > 0) \quad (14)$$

正态分布 $X \sim N(\mu, \sigma^2)$

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad x \in R \quad (15)$$

参数 $\mu = 0, \sigma = 1$ 的正态分布称为标准正态分布, 记为 $X^* \sim N(0, 1)$ 。其概率密度 $\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$. 分布函数 $\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt$

3 二维随机变量及分布律

3.1 二维随机变量

对随机试验 E 的样本空间 Ω , 若对 Ω 中任一样本点 ω , 存在实数 $(X(\omega), Y(\omega))$ 与之对应, 则称 (X, Y) 为二维随机变量

3.2 (联合) 分布函数

定义:

$$F(x, y) = P(\{X \leq x\} \cap \{Y \leq y\}) = P(X \leq x, Y \leq y) \quad (16)$$

联合分布函数的性质:

$$\begin{aligned} 1. \quad & 0 \leq F(x, y) \leq 1 \\ & F(-\infty, y) = F(x, -\infty) = F(-\infty, -\infty) = 0, F(+\infty, +\infty) = 1 \end{aligned}$$

2. 固定其他变量, 对某一特定变量是单调不减函数。

3. 固定其他变量, 关于某特定变量右连续

4. 对于任意的 a, b, c, d , 满足 $a < b, c < d$, 有:

$$F(b, d) - F(a, d) - F(b, c) + F(a, c) = P(a < X \leq b, c < Y \leq d) \geq 0$$

NOTE: 不像一维那样, 这里存在只满足前三点不满足第四点的函数 (但第四点是用定义推出来的)

3.3 边缘分布函数

定义：边缘分布函数为 $F_X(x)$ 和 $F_Y(y)$.

性质： $F_X(x) = F(x, +\infty)$, $F_Y(y) = F(+\infty, y)$

3.4 二维离散随机变量

定义：样本点可列， p_{ij} 为分布律。 $F(x, y) = \sum_{i=-\infty}^x \sum_{j=-\infty}^y p_{ij}$.

$$P((X, Y) \in D) = \sum_{(i,j) \in D} p_{i,j}$$

3.5 二维连续随机变量

定义：若存在非负可积函数 $f(x, y)$, s.t. $F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(u, v) du dv$

$$P((X, Y) \in D) = \iint_D f(x, y) dx dy$$

3.6 条件分布

离散： $P(X = x_i | Y = y_j) = \frac{p_{i,j}}{p_{\cdot,j}}$

连续：在 $\{Y=y\}$ 条件下 X 的条件概率密度： $f_{X|Y}(x|y) = \frac{f(x, y)}{f_Y(y)}$

3.7 独立性

$$F(x, y) = F_X(x)F_Y(y).$$

$$p_{i,j} = p_{i,\cdot} p_{\cdot,j}$$

$$f(x, y) = f_X(x)f_Y(y)$$

3.7.1 独立性的定理

1. 设 X, Y 为相互独立的随机变量， $u(x), v(y)$ 为连续函数。则 U, V 也相互独立
2. 若 X, Y 在相互独立的定义域上，有 $f(x, y) = r(x)g(y)$ ，则 X, Y 独立。

3.8 二维随机变量函数的分布

$$P(Z = z_k) = \sum_{g(x_{i_k}, y_{j_k}) = z_k} P(X = x_{i_k}, Y = y_{j_k})$$

Poisson分布、二项分布可加 (X, Y 独立)

(17)

$$F_Z(z) = \iint_{g(x,y) \leq z} f(x, y) dx dy$$

3.8.1 卷积，一般线性函数的分布

$$f(z) dz = f(z) dz \wedge R \quad (\text{不太对})$$

3.8.2 正态分布可加

3.8.3 m 个独立指数分布的最小 $\min\{X_1, X_2, \dots, X_m\} \sim E(m\lambda)$

4 随机变量的数字特征

4.1 期望

4.1.1 定义：绝对收敛

4.1.2 公式

(对于同一个样本空间下，在同样的随机分布中不同的随机变量 X_i 有：)

线性： $E((\sum A_i X_i + B_i)) = \sum A_i E X_i + b_i$,

独立时 $E(\prod X_i) = \prod E(X_i)$

多维时总可以把联合分布合起来，这样就是同一个分布函数下的变量问题。

4.2 方差

4.2.1 定义

方差： $D(X) = E[X - EX]^2 = E(X^2) - (EX)^2$

标准差： $\sigma_X = \sqrt{D(X)}$

多维则用联合概率分布。

4.2.2 性质

D 存在 $\iff E(X^2) < +\infty$.

$D(X - Y) = D(X) + D(Y) - 2E[(X - EX)(Y - EY)]$

$D(\sum a_i X_i + b) = \sum a_i^2 D(X_i)$

4.3 标准化随机变量

$$X^* = \frac{X - E(X)}{\sqrt{D(X)}} \implies EX^* = 0, DX^* = 1$$

4.4 协方差和相关系数

4.4.1 定义

$\text{cov}(X, Y) = E[(X - EX)(Y - EY)]$

$$\rho_{XY} = \frac{E[(X - EX)(Y - EY)]}{\sqrt{D(X)}\sqrt{D(Y)}} = E[(X^* - EX^*)(Y^* - EY^*)]$$

4.4.2 公式

$$\rho_{XY} = \frac{cov(X, Y)}{\sqrt{D(X)}\sqrt{D(Y)}} = cov(X^*, Y^*)$$

$$cov(X, Y) = E(XY) - E(X)E(Y)$$

$$D(X) = cov(X, X)$$

4.4.3 性质

独立一定不相关，相关一定不独立。

不独立不一定相关，不相关不一定独立

线性：

$$cov\left(\sum_i a_i X_i, \sum_j b_j Y_j\right) = \sum_i \sum_j a_i b_j cov(X_i, Y_j)$$

Cauchy-Schwarz:

$$|cov(X, Y)| \leq \sqrt{D(X)D(Y)}$$

证 $cov(x, y)$ 是内积：线性，可交换

正定： $cov(x, x) \geq 0$

4.5 高阶矩

k 阶原点矩 $E(X^k)$

k 阶中心矩 $E([X - E(X)]^k)$

X 和 Y 的 $k+l$ 阶混合原点矩 $E(X^k Y^l)$

X 和 Y 的 $k+l$ 阶混合中心矩 $E([X - EX]^k [Y - EY]^l)$

4.5.1 协方差矩阵

$$c_{ij} = cov(X_i, X_j) \quad (18)$$

$$C = \begin{pmatrix} c_{ij} \end{pmatrix} \quad (19)$$

性质：（内积）

n 维正态分布：

$$f(x_1, x_2, \dots, x_n) = \frac{1}{(2\pi)^{n/2} |C|^{1/2}} e^{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^T C^{-1}(\mathbf{x}-\boldsymbol{\mu})} \quad (20)$$

5 大数定理和中心极限

5.1 Chebyshev Inequality

$$P(|X - E(X)| \geq \epsilon) \leq \frac{\sigma^2}{\epsilon^2}, \quad \forall \epsilon > 0$$

5.2 依概率收敛

已知 $\{Y_n\} = Y_1, Y_2, \dots, Y_n$, X 是一个随机变量。依概率收敛定义为: $\forall \epsilon > 0$,

$$\lim_{n \rightarrow +\infty} P(|Y_n - X| \geq \epsilon) = 0 \text{ or } \lim_{n \rightarrow +\infty} P(|Y_n - X| < \epsilon) = 1$$

这里 X 一般单值, 也可以 $Y_n = X + X_n$, 但可能独立不太行

5.3 大数定律——次数多起来后频率趋于期望

5.3.1 Bernoulli 大数定理——二项分布的频率收敛于概率

5.3.2 Chebyshev 大数定律

设 $\{X_n\}$ 两两不相关, 方差存在且一致有界, 则

$$\lim_{n \rightarrow +\infty} P\left(\left|\frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} \sum_{i=1}^n a_i\right| < \epsilon\right) = 1$$

但需要注意普遍来说这里需要方差, 极限只要求期望。这不好

5.3.3 Khintchine 大数定律

$\{X_n\}$: 独立同分布 **I,I,D** 且期望存在, 则

$$\lim_{n \rightarrow +\infty} P\left(\left|\frac{1}{n} \sum_{k=1}^n X_k - E(X)\right| \geq \epsilon\right) = 0$$

变化一下, $X^k \rightarrow E(X_k)$

5.4 中心极限定理

5.4.1 独立同分布的中心极限定理

设 $\{X_n\}$ 为独立同分布的随机变量序列, 且他们的期望方差都存在。

$E(X_k) = \mu, D(X_k) = \sigma^2$, 则对任意实数 x , 有:

$$\lim_{n \rightarrow +\infty} P\left(\frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n}\sigma} \leq x\right) = \Phi(x) \quad (21)$$

若记 $\sum_{k=1}^n X_k$ 的标准化随机变量为 $Y_n = \frac{\sum_{k=1}^n X_k}{\sqrt{n}\sigma}$, 即 $Y_n \sim N(0, 1)$

5.4.2 De Moivre-Laplace 中心极限定理

设随机变量 $Y_n \sim B(n, p)$, $0 < p < 1, n = 1, 2$, 则对任一实数 x , 有:

$$\lim_{n \rightarrow +\infty} P\left(\frac{Y_n - np}{\sqrt{np(1-p)}} \leq x\right) = \Phi(x) \quad (22)$$

6 统计

6.1 基本概念

总体： 研究对象的某个（或某些）数量指标的全体称为总体

个体： 总体的每个元素（数量指标）

样本： 总体的部分

样本观测值： 样本值

样本空间： 样本 (X_1, X_2, \dots, X_n) 的所有可能取值的集合 $\chi = \{(x_1, x_2, \dots, x_n)\}$

简单随机样本： 独立同分布

6.2 简单随机样本

6.2.1 统计量

设 (X_1, X_2, \dots, X_n) 为总体 X 的简单随机样本， $g(r_1, r_2, \dots, r_n)$ 是一个实值连续函数，且不含除自变量之外的未知参数。

称随机变量 $g(X_1, X_2, \dots, X_n)$ 为**统计量**， $g(x_1, x_2, \dots, x_n)$ 为样本值

6.2.2 常用统计量

样本均值 \bar{X}, \bar{x}

样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$, s^2 \bar{X} 是一个变量，导致不能提出去。

样本标准差 $S = \sqrt{S^2}$, s

样本 k 阶原点矩 $M_k = \frac{1}{n} \sum_{i=1}^n X_i^k, m_k$

样本 k 阶中心矩 $(CM)_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$, $(cm)_k$

顺序统计量 $\text{sort}((X_1, X_2, \dots, X_n))$, 极差

NOTE!! X (or \bar{X}) 不是一个数，而是一个随机变量（分布）

$$E(\bar{X}) = \mu, \bar{X} \neq E(X), D(\bar{X}) = \frac{\sigma^2}{n}, E(S^2) = \sigma^2$$

分位数

对于连续随机变量 X ，给定 $0 < \alpha < 1$.

若 $P(X > x_\alpha) = \alpha$ ，则 x_α 为 X 所服从分布的上侧 α 分位数。

若 $f(x)$ 为偶函数，则如果 $P(|X| > x_{\alpha/2}) = \alpha$ ，则 $x_{\alpha/2}$ 为 X 服从分布的双侧 α 分位数

$$x_{\alpha/2} = x_{1-\alpha/2}$$

6.3 常用分布

正态分布

χ^2 分布 设 $\{X_n\}$ 独立且 $X_i \sim N(0, 1)$, 则称统计量 $\chi^2 = \sum_{i=1}^n X_i^2$: 服从自由度为 n 的 χ^2 分布, 记为 $\sum_{i=1}^n X_i \sim \chi^2(n)$.

$$f_{\chi^2}(x) = \begin{cases} \frac{1}{2^{\frac{n}{2}} \Gamma(\frac{n}{2})} e^{-\frac{x}{2}} x^{\frac{n}{2}-1}, & x > 0 \\ 0, & x \leq 0 \end{cases} \quad (23)$$

其中 $\Gamma(x) = \int_0^{+\infty} t^{x-1} e^{-t} dt$

$$1. E(\chi^2) = n, D(\chi^2) = 2n$$

性质: 2. $X_1 \sim \chi^2(n_1), X_2 \sim \chi^2(n_2)$, 且 X_1, X_2 独立, 则 $X_1 + X_2 \sim \chi^2(n_1 + n_2)$

3. n 很大时, χ^2 近似服从 $N(n, 2n)$.

t 分布 $X \sim N(0, 1), Y \sim \chi^2(n)$ 且 X, Y 独立, 则 $T = \frac{X}{\sqrt{Y/n}} = \frac{X}{\sqrt{\chi^2(n)/n}}$: 服从自由度为 n 的 t 分布, 记为 $T \sim t(n)$.

$$f(t) = \frac{\Gamma(\frac{n+1}{2})}{\sqrt{n\pi} \Gamma(\frac{n}{2})} (1 + \frac{t^2}{n})^{-\frac{n+1}{2}}, \quad t \in R \quad (24)$$

$$1. f(t) = -f(t)$$

性质 2. $n \rightarrow +\infty, f(t) \rightarrow \varphi(t) = \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}}$

3. 上侧 α 分位数 $t_\alpha(n) : t_{1-\alpha}(n) = -t_\alpha(n)$

F 分布 设 $U \sim \chi^2(m), V \sim \chi^2(n)$, 且 U 与 V 独立, 则称随机变量 $F = \frac{U/m}{V/n} = \frac{\chi^2(m)/m}{\chi^2(n)/n}$: 服从第一自由度为 m , 第二自由度为 n 的 F 分布, 记为 $F \sim F(m, n)$

$$f_F(t) = \begin{cases} \frac{\Gamma(\frac{m+n}{2})}{\Gamma(\frac{m}{2})\Gamma(\frac{n}{2})} (\frac{m}{n})^{\frac{m}{2}} t^{\frac{m}{2}-1} (1 + \frac{m}{n}t)^{-\frac{m+n}{2}} & t > 0, \\ 0 & t \leq 0 \end{cases} \quad (25)$$

性质 1. $F \sim F(m, n), \frac{1}{F} \sim F(n, m)$

2. $F(m, n)$ 的上侧 α 分位数 $F_\alpha(m, n) : F_{1-\alpha}(m, n) = \frac{1}{F_\alpha(n, m)}$

6.4 正态总体的抽样分布

$X \sim N(\mu, \sigma^2)$, $\{X_i\} \sim N(\mu, \sigma^2)$ 是来自总体的 *i.i.d.* 独立同分布。

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim N(\mu, \sigma^2/n) \quad (26)$$

$$\frac{(n-1)S^2}{\sigma^2} = \sum \frac{(X_i - \bar{X})^2}{\sigma^2} \sim \chi^2(n-1) \quad (27)$$

$$\bar{X} \text{ 与 } \frac{(n-1)S^2}{\sigma^2} \text{ 独立} \quad (28)$$

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1) \quad (29)$$

$$\frac{\bar{x} - \mu}{S/\sqrt{n}} \sim t(n-1) \quad (30)$$

两个正态总体的情形

$\{X_n\} \sim N(\mu_1, \sigma_1^2)$, $\{Y_m\} \sim N(\mu_2, \sigma_2^2)$. 且 X, Y 独立

$$\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n-1, m-1). \quad (31)$$

若 $\sigma_1 = \sigma_2 = \sigma$:

$$\bar{X} - \bar{Y} \sim N(\mu_1 - \mu_2, \frac{\sigma^2}{n} + \frac{\sigma^2}{m}) \quad (32)$$

$$\text{由可加性 } \frac{(n-1)S_1^2}{\sigma^2} + \frac{(m-1)S_2^2}{\sigma^2} \sim \chi^2(m+n-2) \quad (33)$$

$$\bar{X} - \bar{Y} \text{ 与 } \frac{(n-1)S_1^2}{\sigma^2} + \frac{(m-1)S_2^2}{\sigma^2} \text{ 独立} \quad (34)$$

$$\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{1}{n} + \frac{1}{m}} \sqrt{\frac{(n-1)S_1^2 + (m-1)S_2^2}{m+n-2}}} \sim T(m+n-2) \quad (35)$$

7 参数估计

7.1 点估计

7.1.1 频率替代法——大数定律

7.1.2 矩估计法

设总体 X 的分布函数为 $F(x; \theta_1, \dots, \theta_k)$, 并假设 k 阶原点矩存在。记

$$E(X^r) = \mu_r(\theta) \quad r = 1, 2, \dots, k \quad (36)$$

则 θ 有 k 个未知数, 需要 k 个方程。从理论上推导出 μ 的 k 个表达式, 将 μ_i 替换成样本矩 M^k , 反解 $\theta = \hat{\theta}$ 。称 $\hat{\theta}(X_1, \dots, X_n)$ 为矩估计量, $\hat{\theta}(x)$ 为矩估计量

7.1.3 极大似然估计

定义似然函数

$$L(\theta) = P(\bigcap_{i=1}^n X_i = x_i) = \prod_{i=1}^n P(x_i; \theta)$$

连续情形下

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta)$$

L 极大, $L(\hat{\theta}) = \max L(\theta)$. 称 $\hat{\theta}(x)$ 为最大似然估计值, $\hat{\theta}(X_1, \dots, X_n)$ 为最大似然估计量

7.2 估计量的评价标准

7.2.1 无偏性

对于 $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$, 若

$$E(\hat{\theta}) = \theta$$

则称 $\hat{\theta}$ 是 θ 的无偏估计量, 反之, 称 $\epsilon = E(\hat{\theta}) - \theta$ 为估计量 $\hat{\theta}$ 的偏差

- 对任意分布 X , \bar{X} 都是总体均值 $\mu = E(X)$ 的无偏估计量, S^2 是 σ^2 的无偏估计量
- $E(\hat{\theta}) = \theta$ 不一定得到 $E(f(\hat{\theta})) = f(\theta)$

7.2.2 有效性

设 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 均为参数 θ 的无偏估计量, 若

$$D(\hat{\theta}_1) < D(\hat{\theta}_2)$$

, 称 θ_1 比 θ_2 有效

• Rao-Cramer 不等式

设总体 X 为离散型随机变量, $P(X = x; \theta) = P(x; \theta)$. (X_1, \dots, X_n) 是简单随机样本

$$D(\hat{\theta}) \geq I(\theta) = \frac{1}{nE[(\frac{\partial \ln P(X; \theta)}{\partial \theta})^2]} \quad (37)$$

设总体 X 为连续性随机变量, 概率密度为 $f(x; \theta)$, $\hat{\theta}$ 是无偏估计量,

$$D(\hat{\theta}) \geq I(\theta) = \frac{1}{nE[(\frac{\partial \ln f(X; \theta)}{\partial \theta})^2]} \quad (38)$$

$I(\theta)$ 称为无偏估计的方差下界。

7.2.3 有效估计量

设 $\hat{\theta}_0$ 是 θ 的无偏估计量, 如果在所有 θ 的无偏估计量 $\hat{\theta}$ 中均有 $D(\hat{\theta}_0) \leq D(\hat{\theta})$. 称 $\hat{\theta}_0$ 是 θ 的有效估计量

7.2.4 一致性

设 $\hat{\theta}_n = \hat{\theta}(X_1, \dots, X_n)$ 是 θ 的估计量, 如果 $\{\hat{\theta}_n\} \xrightarrow{P} \theta$, 则称 $\hat{\theta}_n$ 是 θ 的一致估计量。

- 不要求无偏。而无偏 + 方差 $\rightarrow 0 \implies$ 一致

7.3 区间估计

设总体 X 的分布函数为 $F(x; \theta)$, $\{X_n\}$ 是一个样本, 若

$$\forall \alpha, \exists \hat{\theta}_1 = \hat{\theta}_1(X_1, \dots, X_n), \hat{\theta}_2 = \hat{\theta}_2(X_1, \dots, X_n). \text{ s.t. } P(\hat{\theta}_1 < \theta < \hat{\theta}_2) = 1 - \alpha$$

成立, 则称区间 $(\hat{\theta}_1, \hat{\theta}_2)$ 是 θ 的置信度为 $1 - \alpha$ 的置信区间, $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 是置信下限和致信上限

枢轴量 $U = U(X_1 \dots X_n; \theta)$ 除 θ 没有其他未知参数, U 分布已知且不依赖于未知参数